

Методологический раздел: выбор стека технологий и архитектуры

Титульный лист

Выполнила: Симонова Виктория Игоревна

Группа: НФИбд-01-23

№ студенческого: 1132236012

Научный руководитель: Диваков Дмитрий Валентинович

Тема исследования: Анализ моделей и алгоритмов поиска ассоциативных правил для оптимизации пространственного размещения товаров в ритейле

Тип задания: Задание №4 (Методологический раздел — Трек П)

Дата сдачи: 05.05.2026

Содержание

- Методологический раздел: выбор стека технологий и архитектуры
 - Титульный лист
 - Содержание
 - 1. Формулировка исследовательской задачи
 - 2. Сравнение библиотек и фреймворков для реализации MBA
 - 3. Обоснование выбора стека технологий
 - 4. Описание архитектурного решения системы
 - Компоненты системы:
 - 5. Ограничения и риски выбранного подхода

1. Формулировка исследовательской задачи

В рамках прикладного трека (П) исследовательская задача сфокусирована на создании программного инструментария для автоматизации принятия решений в мерчандайзинге.

- **Объект исследования:** Система управления выкладкой товаров в продуктовом ритейле.
- **Предмет исследования:** Методика интеграции результатов ассоциативного анализа (Market Basket Analysis) с инженерно-техническими параметрами торгового оборудования.
- **Проблема:** Классические алгоритмы интеллектуального анализа данных (Apriori, FP-Growth) функционируют в «абстрактном» цифровом пространстве. Полученные правила (например, «Замороженная рыба $\rightarrow$ Белое вино») игнорируют физическую невозможность размещения этих товаров в одной температурной зоне.
- **Гипотеза:** Внедрение многокритериальной фильтрации ассоциативных правил через «штрафную функцию физических ограничений» позволит создавать планограммы, которые одновременно максимизируют вероятность кросс-продаж и соответствуют техническому паспорту магазина.

2. Сравнение библиотек и фреймворков для реализации MBA

Для построения математического ядра системы был проведен сравнительный анализ инструментария на языке Python:

Критерий	MLxtend	PySpark (MLlib)	Apyori
Реализованные алгоритмы	Apriori, FP-Growth, FP-Max	FP-Growth (распределенный)	Только Apriori
Производительность	Высокая на малых и средних данных	Экстремальная (Big Data)	Низкая
Сложность внедрения	Низкая (библиотека для Data Science)	Высокая (требуется Spark-кластер)	Минимальная
Интеграция с Pandas	Полная (нативная поддержка)	Через Spark DataFrame	Отсутствует
Применимость в проекте	Оптимально для прототипа	Избыточно	Не рекомендуется

3. Обоснование выбора стека технологий

На основе анализа предметной области и необходимости оперативной разработки прототипа выбран следующий стек:

1. **Язык программирования: Python 3.10+**. Выбор обусловлен наличием развитой экосистемы библиотек для статистического анализа.
2. **Среда выполнения: Google Colab**. Обеспечивает воспроизводимость результатов, облачное хранение данных и интеграцию с Google Drive для работы с датасетами без локальной настройки окружения.
3. **Обработка данных (Pandas/NumPy)**: Для трансформации «сырых» транзакционных логов в матрицу покупок.
4. **Математическое ядро (MLxtend)**: Использование алгоритма **FP-Growth** обосновано его превосходством над Apriori в части использования памяти и скорости обработки (за счет построения префиксного дерева без генерации кандидатов).
5. **Статистическая верификация (SciPy)**: Для реализации проверки через **гипергеометрическое распределение** по рекомендации научного руководителя Дивакова Д. В.

4. Описание архитектурного решения системы

Архитектура системы строится по модульному принципу, что позволяет гибко настраивать «веса» ограничений.

Компоненты системы:

1. Модуль ETL (Extract, Transform, Load):

- Загрузка транзакций магазина (CSV/Excel).
- Агрегация данных: приведение чеков к формату One-Hot Encoding.

2. Аналитическое ядро (Rule Generator):

- Генерация правил через FP-Growth.
- Расчет метрик: Support, Confidence, Lift.

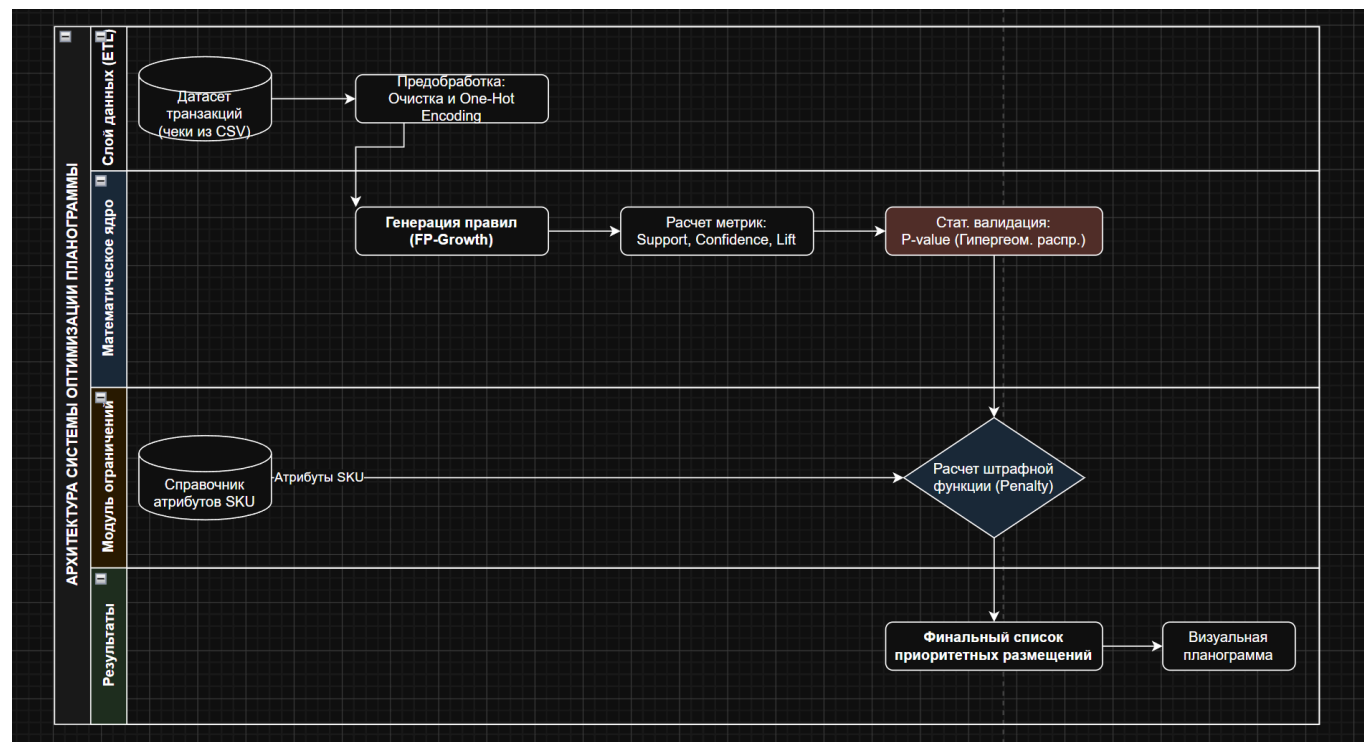
3. Статистический валидатор:

- Расчет вероятности случайного совпадения через гипергеометрическую функцию.
- Фильтрация правил по порогу $p\text{-value} < 0.05$.

4. Модуль пространственных ограничений (Spatial Filter):

- Сопоставление товаров с базой атрибутов (тип полки, габариты, потребность в электричестве).
- Расчет итогового ранга правила: $\text{Final_Rank} = \text{Lift} \times (1 - \text{Penalty})$.

5. Блок вывода (Output): Генерация рекомендаций для планограммы.



5. Ограничения и риски выбранного подхода

- **Риск разреженности данных (Sparsity):** При очень широком ассортименте и малом количестве чеков многие связи не наберут порог поддержки (Support).
- **Ограничение модели маппинга:** В текущей итерации архитектура предполагает статичное расположение розеток и холодильников. Динамическое изменение конфигурации зала требует

пересчета всей модели.

- **Вычислительный риск:** Алгоритм FP-Growth чувствителен к объему оперативной памяти при построении дерева. При превышении лимитов Google Colab потребуются переход на использование генераторов или чанков данных.